Integração e análise do Mundial 2026: jogadores e plantéis

Trabalho Prático I – Integração de Sistemas de Informação (2026/27)
Licenciatura em Engenharia de Sistemas Informáticos – Escola Superior de Tecnologia, IPCA

Autor: João Castro nº 21143
Plataforma: KNIME Analytics Platform 5.12
Repositório: https://github.com/joao10castro/ISI_2026-27_TP01_21143

1. Enquadramento

Este relatório documenta o Trabalho Prático I da unidade curricular de Integração de Sistemas de Informação (ISI), do curso de Engenharia de Sistemas Informáticos da Escola Superior de Tecnologia do IPCA, no ano letivo 2026/27. O trabalho foca a aplicação e experimentação de ferramentas em processos de ETL (*Extract*, *Transform and Load*), ao nível da integração de dados.

O tema escolhido é a integração e análise de dados do Campeonato do Mundo de futebol de 2026. O tema é partilhado com um colega, o André, que trata a parte das seleções e dos jogos (grupos, classificações, confederações e alertas de resultados) na plataforma Pentaho Kettle. Cada elemento explora uma plataforma diferente e tem o seu próprio repositório, como pede o enunciado. Este relatório e o repositório associado cobrem apenas a minha parte: **jogadores e plantéis** (golos, clubes de origem, idades e melhores marcadores), desenvolvida em **KNIME**.

Elemento	Detalhe
Unidade curricular	Integração de Sistemas de Informação (2026/27)
Curso	Licenciatura em Engenharia de Sistemas Informáticos
Autor	João Castro nº 21143
Plataforma	KNIME Analytics Platform 5.12
Tema	Mundial 2026: jogadores e plantéis

2. Problema

Os dados de um grande torneio estão espalhados por vários ficheiros e formatos: plantéis, seleções, eventos de jogo (golos, assistências, cartões), convocatórias e detalhes dos jogos. Cada ficheiro, sozinho, responde a poucas perguntas. O objetivo deste trabalho é construir um processo de ETL que consiga:

- extrair dados de várias fontes, em mais do que um formato (CSV e JSON);
- cruzar jogadores com seleções e eventos de jogo, para responder a perguntas como *quem foram os melhores marcadores?* e *qual a idade média de cada seleção?*;
- validar a qualidade dos dados (duplicados, tipos e consistência);
- persistir e exportar os resultados em formatos reutilizáveis (CSV, JSON e base de dados SQLite).

Os dados vêm do dataset *FIFA World Cup 2026* de MD Mominul Islam, publicado em GitHub, Kaggle e Zenodo (licença CC0, DOI 10.5281/zenodo.21592427). Segundo a documentação do autor, o dataset contém 48 seleções, 1.248 jogadores e 104 jogos, e relaciona as tabelas por chaves (player_id, team_id, match_id). A própria documentação refere que os valores de mercado combinam valores verificados com estimativas, o que limita o seu uso analítico e justifica uma abordagem cautelosa na interpretação dos resultados.

3. Estratégia utilizada

O processo foi organizado nas três fases do enunciado, dentro de um único workflow KNIME.

Fase 1 – Extração (E)

Foram usadas duas famílias de fontes, em dois formatos:

Formato	Ficheiro	Nó de leitura	Conteúdo
CSV	squads_and_players.csv	CSV Reader (Jogadores)	Jogadores, posição, clube, caps, data de nascimento, golos
CSV	teams.csv	CSV Reader (Seleções)	Seleções, grupo, confederação, ranking
CSV	match_events.csv	CSV Reader (Eventos)	Golos, assistências, cartões, por jogo e jogador
CSV	match_lineups.csv	CSV Reader (Lineups)	Convocatórias e minutos jogados
CSV	player_stats.csv	CSV Reader (Stats_Jogadores)	Estatísticas agregadas por jogador
JSON	real_match_details.json	JSON Reader (Jogos JSON)	Resultados e detalhes dos jogos

Fase 2 – Transformação (T)

Operadores principais: **Joiner** (cruzamento por chave), **String to Date&Time** e **Date&Time Difference** (conversão e cálculo), **Duplicate Row Filter** (validação), **String Manipulation** com expressões regulares, **Row Filter** (filtragem), **GroupBy** (agregação) e **Sorter** (ordenação). A transformação do JSON usa **JSON Path** e **Ungroup**.

Fase 3 – Carregamento (L)

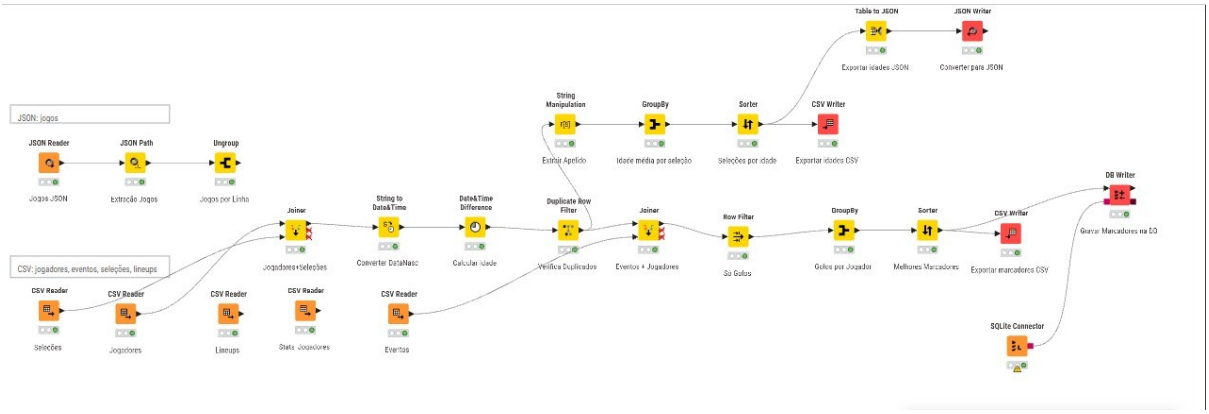
Os resultados são exportados com **CSV Writer** e **JSON Writer** (precedido de **Table to JSON**) e persistidos numa base de dados SQLite com **SQLite Connector** e **DB Writer**.

Decisão sobre a base de dados

O computador de desenvolvimento tem o SQL Server (LocalDB) instalado. Esta opção foi avaliada e posta de parte: o LocalDB só aceita ligações por *named pipe*, cujo nome muda sempre que a instância reinicia, e a autenticação Windows exige configuração adicional no KNIME. Optou-se por

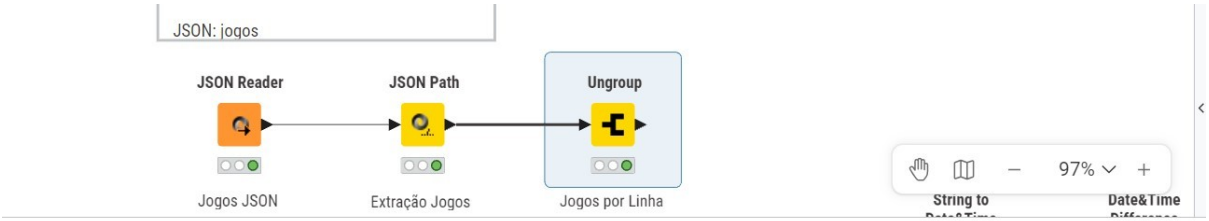
SQLite, que guarda a base de dados num único ficheiro, não depende de um servidor e é totalmente reproduzível a partir do repositório.

4. Transformações



4.1 Extração do JSON (ramo “JSON: jogos”)

O JSON Reader carrega o ficheiro inteiro como uma única célula do tipo JSON. Para obter uma linha por jogo, o JSON Path (Extração Jogos) extrai cada campo da lista de jogos ($[*].match_id, $[*].home_team, $[*].away_team, $[*].home_score, $[*].away_score), com a opção de lista ativa. O Ungroup (Jogos por Linha) expande as listas em linhas, resultando em **104 linhas**, uma por jogo. Esta etapa é uma conversão de formato (JSON para tabela).



▶ 1: Data table Flow Variables

Rows: 104 | Columns: 6 Sorting Filter Table Statistics Search

#	RowID	json {} JSON	match_id {} JSON	home_team {} JSON	away_team {} JSON	home_score {} JSON	away_score {} JSON
1	Row0…	[{ "match_id" : "home_team" : "away_team" : "home_score" "away_score" "home_goals"	1	"Mexico"	"South Africa"	2	0
2	Row0…	[{ "match_id" : "home_team" : "away_team" : "home_score" "away_score" "home_goals"	2	"South Korea"	"Czechia"	2	1
3	Row0…	[{ "match_id" :	3	"Canada"	"Bosnia and Her	1	1

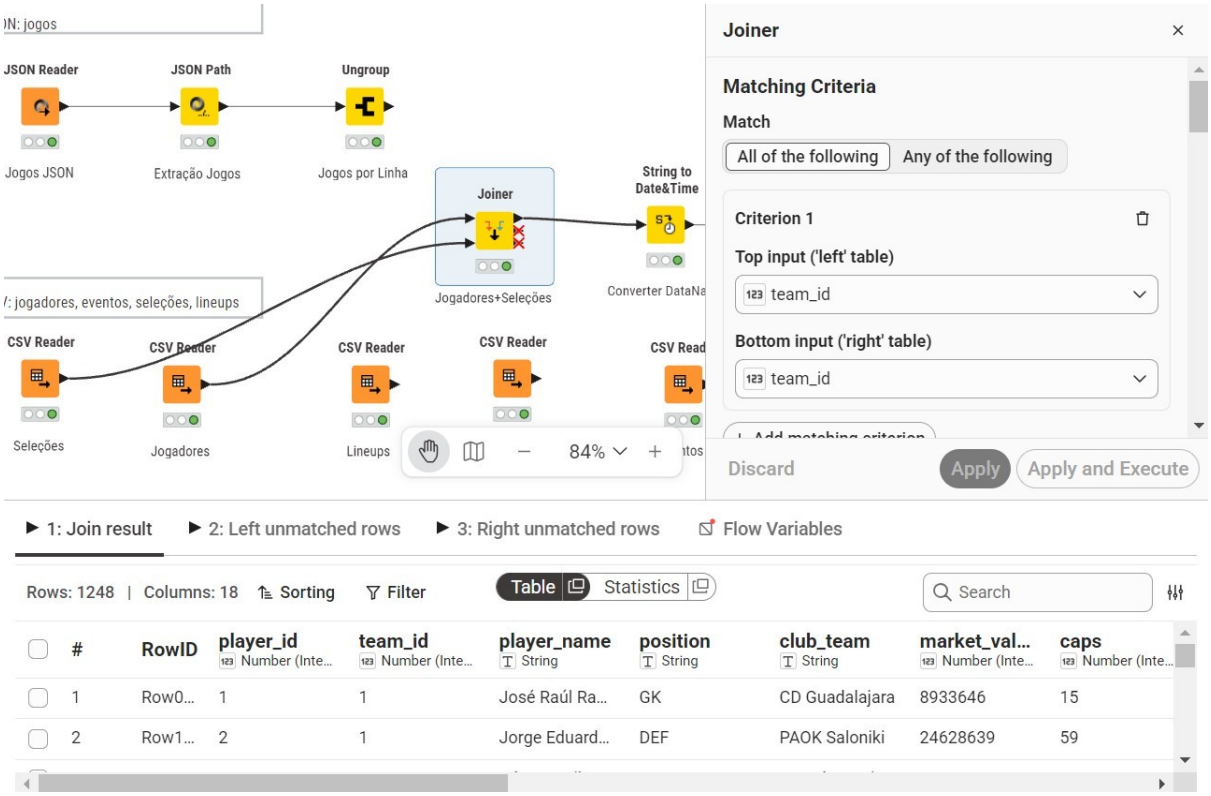
Num primeiro ensaio, extrair o jogo inteiro ($[*]) devolvia o conteúdo como texto e impedia a extração de campos. A solução foi extrair cada campo individualmente. As colunas resultantes

mantêm o tipo JSON, pelo que uma melhoria futura é convertê-las para texto e inteiros antes de as usar em junções.

4.2 Jogadores e seleções (Jogadores + Seleções)

O Joiner cruza Jogadores e Seleções pela chave team_id, em *inner join*. O resultado tem **1.248 linhas** (um jogador por linha) e acrescenta a cada jogador o nome da seleção, o código FIFA, o grupo, a confederação, o ranking, o rating ELO e o selecionador.

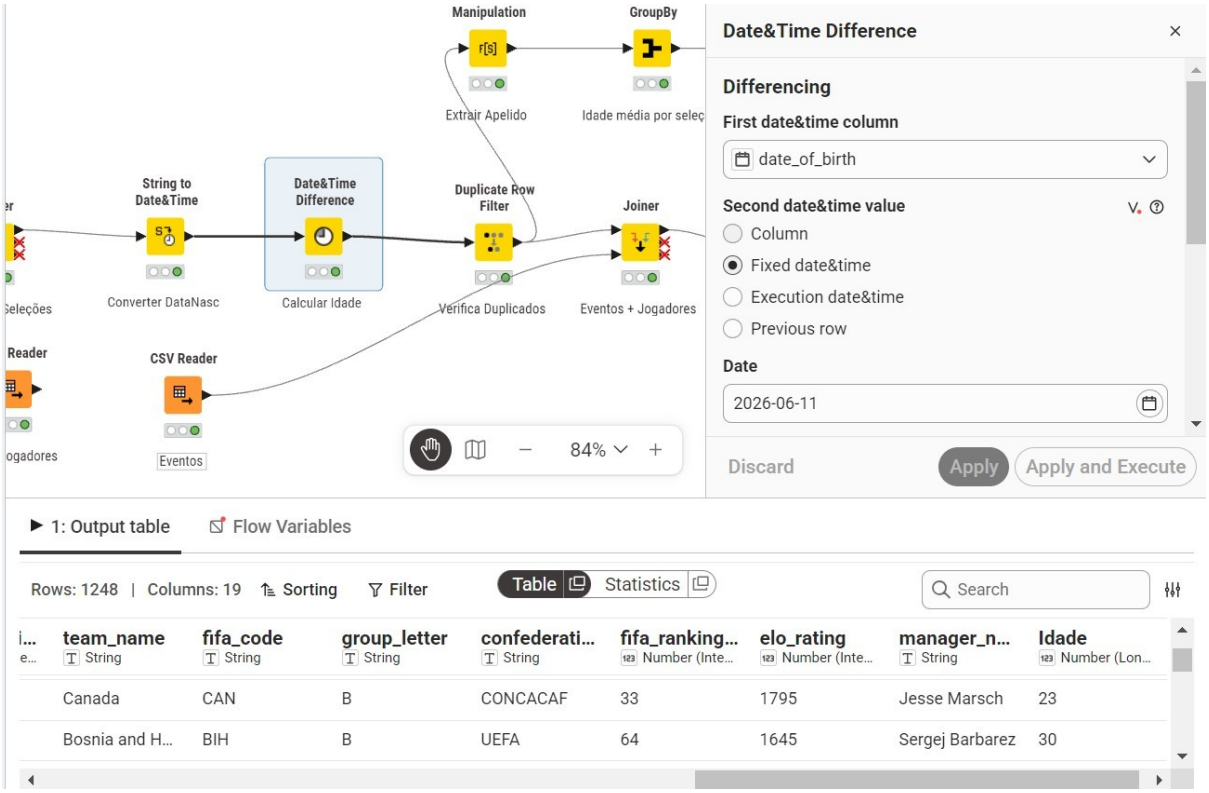
A primeira configuração do Joiner emparelhava por omissão a primeira coluna de cada tabela (player_id com team_id) e devolvia apenas 48 linhas. A verificação do número de linhas permitiu detetar o erro e corrigir o critério. Esta situação reforçou a importância de validar a cardinalidade depois de cada junção.



#	RowID	player_id	team_id	player_name	position	club_team	market_val...	caps
		Number (Inte...	Number (Inte...	String	String	String	Number (Inte...	Number (Inte...
1	Row0...	1	1	José Raúl Ra...	GK	CD Guadalajara	8933646	15
2	Row1...	2	1	Jorge Eduard...	DEF	PAOK Saloniki	24628639	59

4.3 Cálculo da idade (Converter DataNasc e Calcular Idade)

A data de nascimento vem como texto no formato AAAA-MM-DD. O nó String to Date&Time converte essa coluna para o tipo data. O nó Date&Time Difference calcula depois a diferença em anos entre a data de nascimento e uma data fixa, **11 de junho de 2026** (início do torneio), criando a coluna Idade. Foi escolhida a idade à data do torneio, em vez da idade atual, para que o resultado seja estável e comparável.

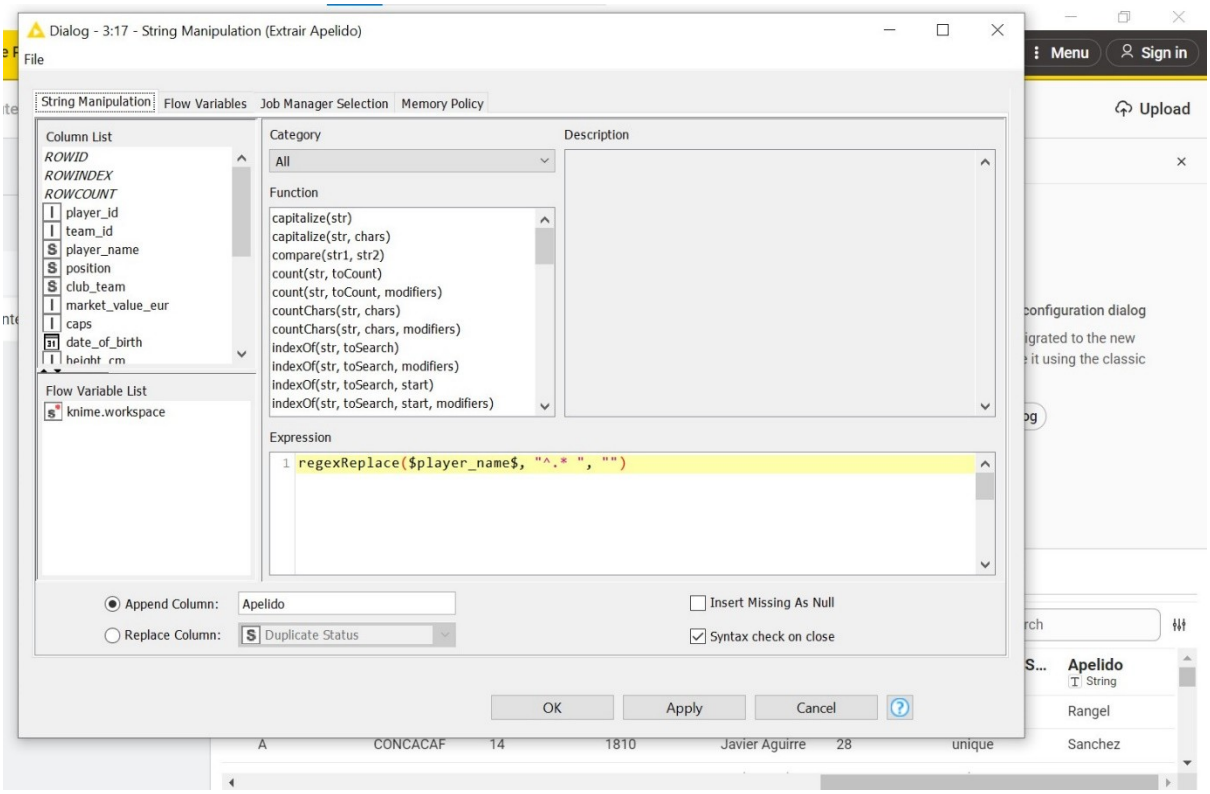


4.4 Validação de duplicados (Verifica Duplicados)

O Duplicate Row Filter foi configurado sobre player_name, no modo *Keep duplicate rows*, que preserva todas as linhas e acrescenta uma coluna de estado (Duplicate Status). Nas estatísticas da tabela, player_id tem 1.248 valores únicos e nenhum valor em falta, enquanto player_name tem 1.241 valores únicos, ou seja, **7 nomes repetidos**. Optou-se por não remover estas linhas, porque nomes iguais podem corresponder a jogadores diferentes. Uma primeira tentativa em modo de remoção eliminava 7 jogadores e foi corrigida.

4.5 Expressões regulares (Extrair Apelido)

O String Manipulation aplica uma expressão regular à coluna player_name para extrair o apelido, removendo tudo até ao último espaço (por exemplo, regexReplace($player_name$, "^.* ", "")). Nomes com uma única palavra ficam inalterados. A coluna apelido serve para normalizar e facilitar cruzamentos por nome noutras fontes.

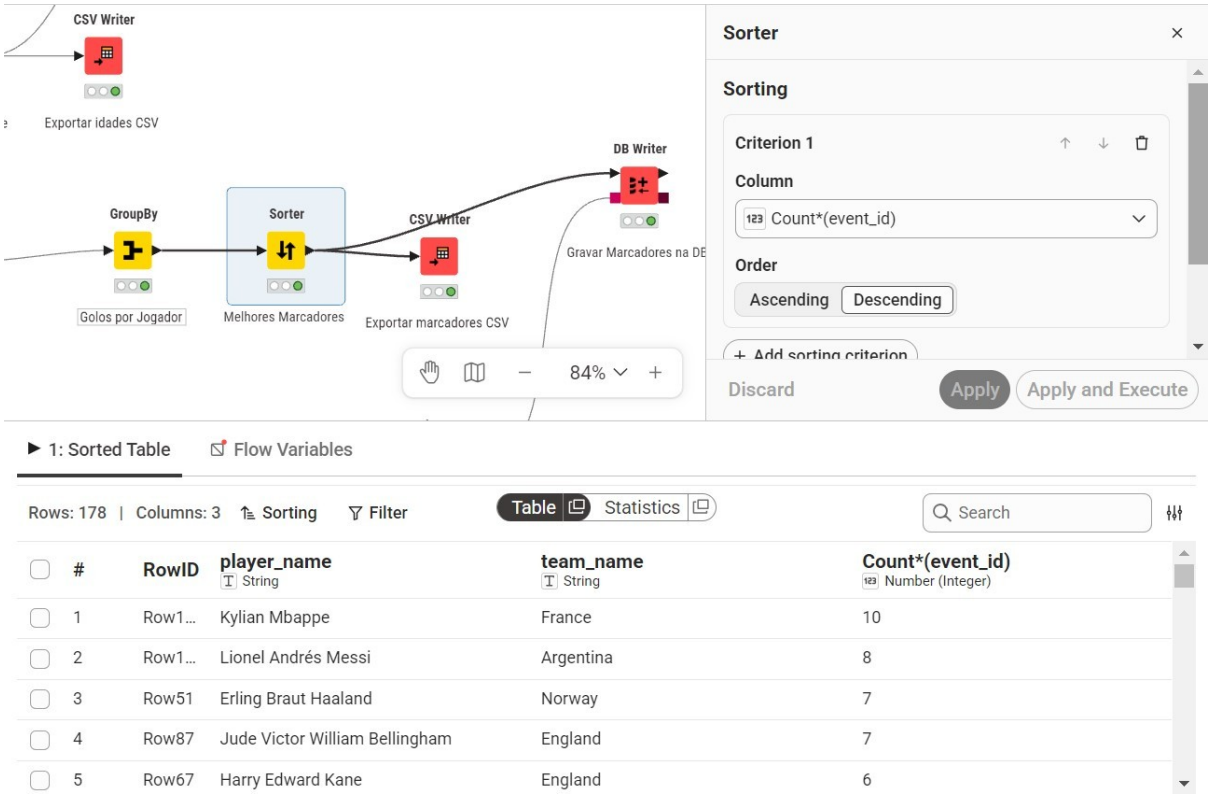


4.6 Melhores marcadores

Este ramo responde à principal pergunta do trabalho:

1. Eventos + Jogadores: Joiner entre Jogadores (já com seleção e idade) e Eventos, por player_id. O resultado tem **601 linhas**, uma por evento.
2. Só Golos: Row Filter com event_type = Goal, que devolve **294 linhas**, valor coerente com o indicado na documentação do dataset. Ficam de fora os autogolos (Own Goal) e os golos de desempate por penáltis.
3. Golos por Jogador: GroupBy por player_name e team_name, com contagem de eventos. Resultam **178 marcadores**.
4. Melhores Marcadores: Sorter por número de golos, em ordem decrescente.

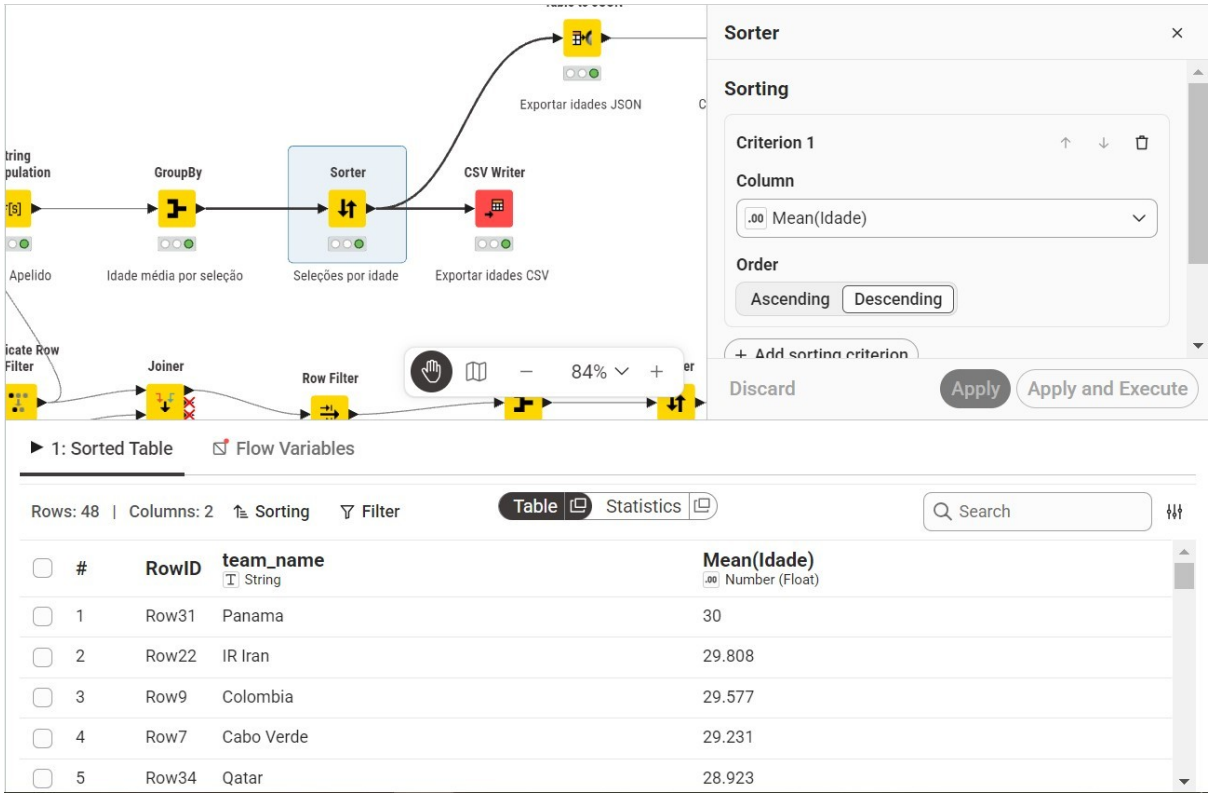
No topo da tabela aparecem Kylian Mbappé (França), com 10 golos, Lionel Messi (Argentina), com 8, e Erling Haaland (Noruega) e Jude Bellingham (Inglaterra), com 7 cada.



#	RowID	player_name (String)	team_name (String)	Count*(event_id) (Number (Integer))
1	Row1…	Kylian Mbappe	France	10
2	Row1…	Lionel Andrés Messi	Argentina	8
3	Row51	Erling Braut Haaland	Norway	7
4	Row87	Jude Victor William Bellingham	England	7
5	Row67	Harry Edward Kane	England	6

4.7 Idade média por seleção

A partir da tabela dos jogadores, um GroupBy por team_name calcula a média de Idade para as **48 seleções**, e um Sorter ordena o resultado (Seleções por idade). Por exemplo, a Argélia tem uma média de 26,46 anos, a Argentina 28,69 e a Austrália 26,89.



#	RowID	team_name (String)	Mean(Idade) (Number (Float))
1	Row31	Panama	30
2	Row22	IR Iran	29.808
3	Row9	Colombia	29.577
4	Row7	Cabo Verde	29.231
5	Row34	Qatar	28.923

5. Jobs

O enunciado valoriza *jobs* ou controlo de processos que orquestrem um projeto completo, incluindo acesso a serviços remotos. Neste trabalho, a orquestração é feita no próprio workflow KNIME: as ligações entre nós definem as dependências, e o comando *Execute all* executa os ramos pela ordem correta (leitura, transformação, exportação e persistência).

A orquestração tem três ramos principais:

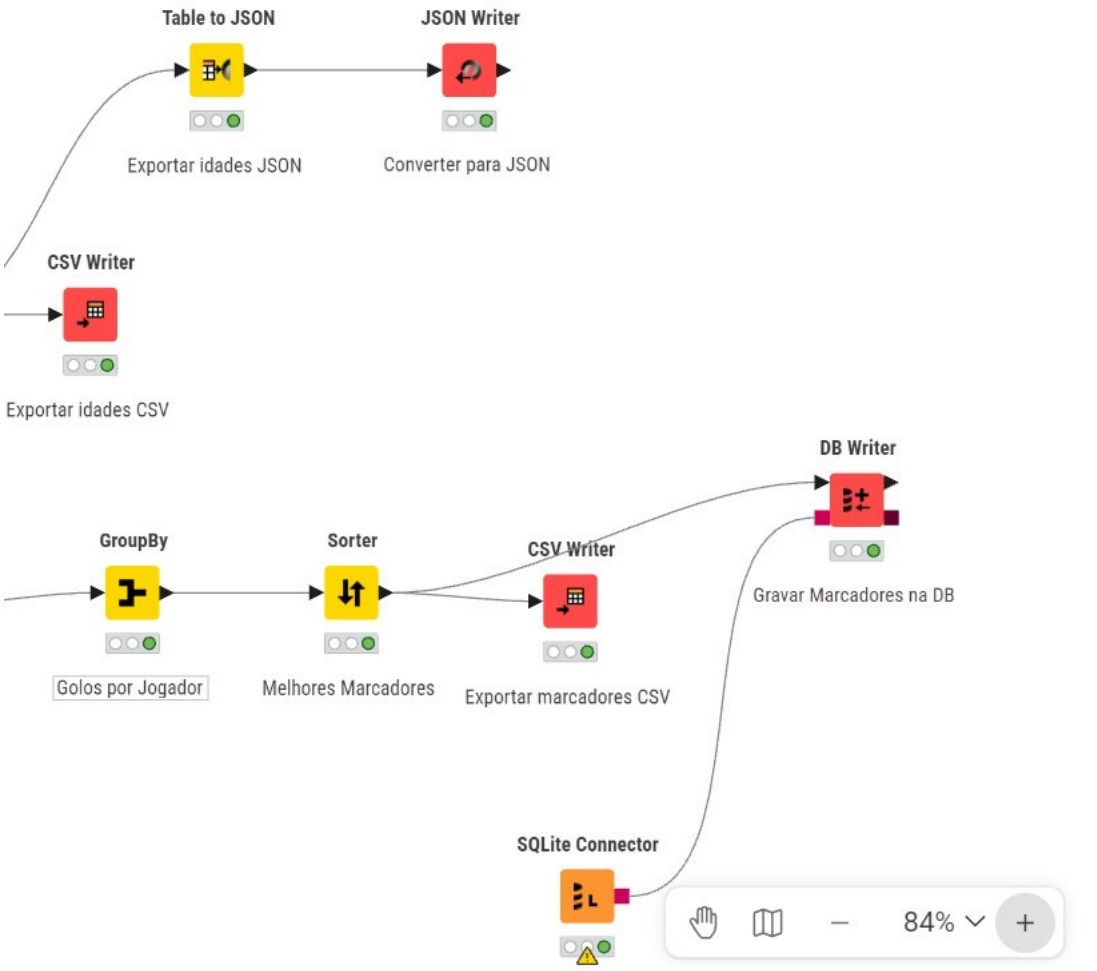
1. **Ramo JSON:** Jogos JSON → Extração Jogos → Jogos por Linha.
2. **Ramo dos jogadores:** leitores CSV → Jogadores + Seleções → Converter DataNasc → Calcular Idade → Verifica Duplicados, que alimenta os dois resultados seguintes.
3. **Ramos de resultados:** Eventos + Jogadores → Só Golos → Golos por Jogador → Melhores Marcadores; e Extrair Apelido → Idade média por seleção → Seleções por idade.

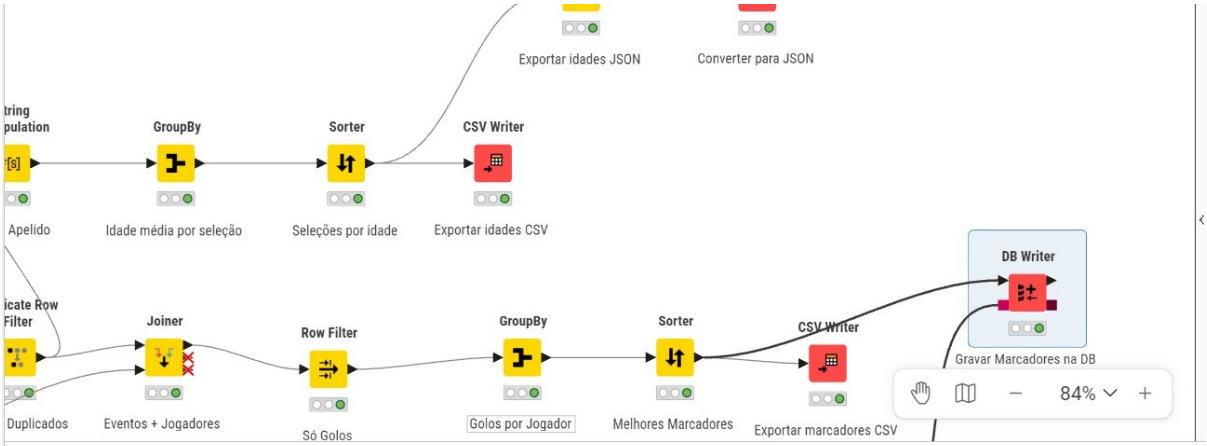
Carregamento e exportação

Nó	Destino
Exportar marcadores CSV	Trabalho/Exports/melhores_marcadores.csv
Exportar idades CSV	Trabalho/Exports/idade_media_selecoes.csv
Converter para JSON + Exportar idades JSON	Trabalho/Exports/idade_media_selecoes_0.json
SQLite Connector + Gravar marcadores na BD	Tabela melhores_marcadores em mundial2026.db (178 linhas)
Send Email	Email com o ficheiro melhores_marcadores.csv em anexo, enviado pelo servidor SMTP do Microsoft 365 (porta 587, STARTTLS)

O JSON Writer grava um ficheiro por linha da tabela de entrada e exige um padrão de nome com o símbolo ?. Como o Table to JSON junta todas as seleções numa única linha, é gerado um só ficheiro, com a lista completa.

O nó Send Email liga-se ao servidor SMTP do Microsoft 365 e envia o ficheiro melhores_marcadores.csv em anexo, sendo executado depois da exportação do CSV. É o acesso a um serviço remoto desta orquestração e serve de notificação de que o processo terminou.

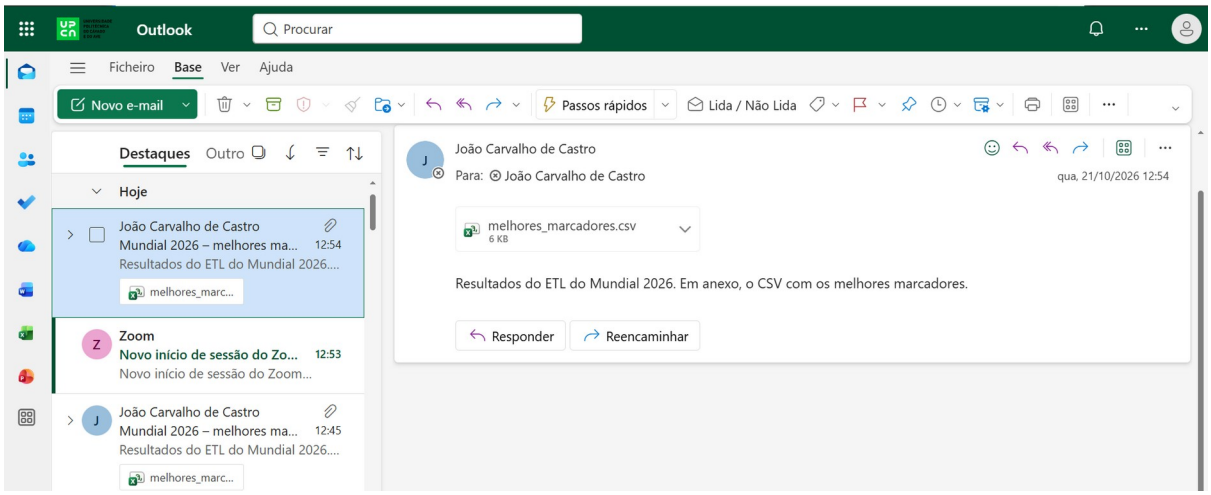

Table to JSON
JSON Writer
Exportar idades JSON
Converter para JSON
CSV Writer
Exportar idades CSV
DB Writer
GroupBy
Sorter
CSV Writer
Gravar Marcadores na DB
Golos por Jogador
Melhores Marcadores
Exportar marcadores CSV
SQLite Connector
84%



▶ 1: Input Data with Write Status ■ 2: DB Data Flow Variables

Rows: 100 | Columns: 3 Open in new window

#	RowID	player_name (String)	team_name (String)	Count*(event_id) (Number (Integer))
1	Row0	Kylian Mbappe	France	10
2	Row1	Lionel Andrés Messi	Argentina	8
3	Row2	Erling Braut Haaland	Norway	7
4	Row3	Jude Victor William Bellingham	England	7



6. Vídeo de demonstração

O vídeo mostra a execução do workflow, a leitura das fontes, os resultados intermédios e os ficheiros exportados.



7. Conclusão e trabalhos futuros

Conclusão

O trabalho permitiu construir um processo de ETL completo no KNIME, com extração de dados em dois formatos (CSV e JSON), transformações variadas (junções, conversão de tipos, cálculo de idade, expressões regulares, filtragem, agregação e ordenação) e carregamento em três tipos de destino (CSV, JSON e SQLite). O processo responde às perguntas propostas: identifica os melhores marcadores do torneio e calcula a idade média por seleção.

O desenvolvimento deixou algumas aprendizagens práticas. A validação da cardinalidade depois de cada junção permitiu detetar um critério mal configurado. A remoção automática de duplicados por nome teria eliminado jogadores legítimos. E a escolha da base de dados deve considerar a reprodutibilidade, não apenas a disponibilidade no computador de desenvolvimento.

O trabalho tem também limitações. Os valores de mercado do dataset são em parte estimados. A verificação de valores em falta foi feita apenas nas colunas-chave (player_id, team_id e player_name). O ramo do JSON não está ligado aos restantes ramos, e os ficheiros Lineups e Stats_Jogadores são lidos, mas ainda não usados nas transformações.

Trabalhos futuros

- Validar os golos calculados a partir dos eventos com os valores de player_stats.csv e da coluna goals.
- Converter as colunas do ramo JSON para tipos nativos e cruzar os resultados dos jogos com os marcadores.
- Tratar sistematicamente os valores em falta (nó *Missing Value*) e anonimizar campos sensíveis, como o nome dos selecionadores.
- Acrescentar visualização (gráficos de barras ou dashboard) dos melhores marcadores e da idade por seleção.
- Automatizar o envio dos resultados por email (nó *Send Email*) ou por SFTP, e orquestrar a execução periódica.

- Integrar os resultados com o trabalho do colega (seleções e jogos), usando team_id ou o código FIFA como chave comum.

8. Referências bibliográficas

- Islam, M. M. (2026). *The FIFA World Cup 2026 Master Dataset: A Normalized 3NF Relational Benchmark of the Expanded 48-Team International Football Tournament*. Zenodo. https://doi.org/10.5281/zenodo.21592427
- Repositório do dataset: https://github.com/mominullptr/FIFA-World-Cup-2026-Dataset
- KNIME AG. *KNIME Analytics Platform*. https://www.knime.com
- Escola Superior de Tecnologia, IPCA (2026). *Integração de Sistemas de Informação – Trabalho Prático I (enunciado)*. Ferreira, L. e Ribeiro, Ó.
- Repositório do trabalho: https://github.com/joao10castro/ISI_2026-27_TP01_21143